实验 07

实验目的

理解并熟悉 DataFrame 数据获取的基本方法，理解并熟悉 DataFrame 的基本操作。熟悉文件读写

实验内容

本次实验共四个练习。大部分小题已提供 py 脚本程序文件，不需要再新建文件。文件内已有的代码不能修改删除；不能建立新行（题目特别提示除外）

7-1A 必须完成，理解数据获取的手段。

超星学习通

将代码截图或者拍照保存，准备下次实验课一起提交

使用说明

将“实验 07 学生文件”整个文件夹复制到个人文件夹中使用。

实验题目

● 练习 7-1　对数据框元素的访问

本练习，请同学们根据操作引导的要求逐步完成，每完成一个步骤运行一次，观察结果，思考代码的含义。

Ex7-1A、操作引导

数据文件 Diabetes.csv 文件保存的是部分糖尿病患者的数据，如下所示。

PatientID	Age	Gender	Height	Weight	Glucose	HTN	Smoking	Type
A01	60	Male	162.5	43.3	288.7	1	0	1
A02	63	Male	183.9	73.1	207.7	0	0	1
A03	52	Male	149.4	51.5	105.9	1	0	1
A04	64	Female	143.5	41.3	269.2	0	0	1

各列数据说明

PatientID：患者编号，每位患者的编号都是唯一的

Age：患者年龄

Gender：患者性别，Male 或者 Female

Height：患者身高，单位厘米

Weight：患者体重，单位公斤

Glucose：患者血糖值，单位　mg/DL

HTN：患者是否高血压，0 为不是，1 为是

Smoking：患者是否抽烟，0 为不是，1 为是

Type：患者的糖尿病分型，1 为 I 型，2 为 II 型

题目要求

请按以下要求，分步骤输入代码并运行

每一步完成之后都尝试运行，确定代码无误，观察运行结果。理解代码的作用，熟悉代码的格式。

步骤 1

```
# 1 读取数据文件到DF1，注意和numpy的区别
DF1 = pd.read_csv("Diabetes.csv",index_col=0)
print("显示原始数据：\n",DF1)
```

注意区别 numpy 读取文件的方式

步骤 2：获取列数据

```
# 2 通过列标签获取单列或多列
print("显示年龄数据")
print(DF1["Age"])
print("显示性别和抽烟数据")
print(DF1[["Gender", "Smoking"]])
```

步骤 3：获取行数据，注意这种方式只能使用切片格式。

```
# 3 通过行索引位置的切片形式获取单行或多行
print("显示第5行数据")
print(DF1[4:5])
print("显示第11行到第15行的数据")
print(DF1[10:15])
```

步骤 4：特殊行的获取方法，默认为 5 行

```
# 4 使用head和tail方法
print("显示前5行")
print(DF1.head())
print("显示前7行")
print(DF1.head(7))
print("显示最后8行")
print(DF1.tail(8))
```

步骤 5：行列切片获取数据子集

```
# 5 使用iloc方法通过索引位置序号做行列切片
print("显示第5到8行的第4列数据")
print(DF1.iloc[4:8, 3])
print("显示前10行的第3列和第6列数据")
print(DF1.iloc[:10, [2, 5]])
```

步骤 6：行列切片获取数据子集，使用行标签和列标签名字

```
# 6 使用loc方法通过索引名称做行列切片
print("显示VIP01行的身高和体重数据")
print(DF1.loc["VIP01", ["Height","Weight"]])
print("显示A01,B01,C01三行的高血压、类型、年龄数据")
print(DF1.loc[["A01","B01","C01"], ["HTN","Type","Age"]])
```

步骤 7：通过条件获取子集

```
# 7 通过布尔索引方式获取满足条件的数据
print("显示性别为男性的所有数据")
print(DF1[DF1["Gender"] == "Male"])
```

Py 程序脚本文件已提供，里面有代码部分内容及提示，请根据提示完成，注意不能更改已有的代码，不能增加代码行。

Ex7-1B、操作实践

数据文件 birthwt.csv 文件保存的是 1986 年美国马萨诸塞州斯湾州医疗中心（Baystate Health）的 189 例分娩数据。用于分析影响新生儿体重的因素

x	low	age	lwt	race	smoke	ptl	ht	ui	ftv	bwt
4	YES	28	120	3	YES	1	NO	YES	0	709
10	YES	29	130	1	NO	0	NO	YES	2	1021
11	YES	34	187	2	YES	0	YES	NO	0	1135
13	YES	25	105	3	NO	1	YES	NO	0	1330
15	YES	25	85	3	NO	0	NO	YES	0	1474
16	YES	27	150	3	NO	0	NO	NO	0	1588

数据说明

x 编号

low 新生儿是否为低体重（2500 克为分类标准），YES 或者 NO

age 孕妇的年龄

lwt 孕妇怀孕前的体重（单位：磅）

race 孕妇的种族

smoke 孕妇是否有吸烟

ptl 孕妇在本次怀孕前的流产次数

ht 孕妇是否有高血压史

ui 孕妇在怀孕期间是否有子宫内感染或出血

ftv 孕妇在本次怀孕前的生育次数

bwt 新生儿的体重（单位：克）

练习要求

读取数据文件，完成以下查询操作。

1 查看数据集

显示所有的列标签名称

显示行列数

2 列查看

显示年龄数据

显示流产次数和生产次数数据

3 特殊行查看

显示最后 5 行数据

显示前 10 行数据

4 iloc 方法

显示第 4 到 10 行的第 8 列数据

从第 21 行开始，取出 10 行第 5 列和第 8 列数据

5 loc 方法

显示行标签名称为 47，列标签为年龄和新生儿体重的数据

6 按条件查看

显示年龄小于 18 并且有吸烟史的数据

Py 程序脚本文件已提供，里面有代码部分内容及提示，请根据提示完成，注意不能更改已有的代码，不能增加代码行。

● 练习 7-2 数据框的基本操作

Ex7-2A、操作引导

课堂上我们讲授了 DataFrame 的增删改查等基本操作。回顾课堂讲授内容，如果不熟悉的同学，最好将讲授过的案例自己写一遍。

Ex7-2B、操作实践

文件 score.csv 中保存的是部分学生的成绩数据。读取这个文件并根据下面的要求完成程序设计

1）读取 csv 文件到 DataFrame 数据框 DF_score，以姓名列为行标签 index，本小题的代码已提供

原始数据：

姓名	语文	数学	英语	物理	化学
刘备	82	99	99	49	85
关羽	81	93	98	63	86
张飞	76	99	98	82	93
赵云	67	72	92	29	73
马超	69	99	98	40	81
黄忠	50	74	90	64	75
魏延	46	55	52	90	76
甘宁	44	86	67	35	70
张辽	18	93	99	58	77

对 DF_score，做如下增加和删除操作

2）直接删除赵云的成绩

3）追加一行数据，index 为"吕布"，数据为 52,63,64,55,53

4）在英语和物理列中插入新列，列标签为“体育”，列数据为["良","中","差","优","优","良","优","中","优"]

显示修改后的数据，如下所示

修改后数据：

姓名	语文	数学	英语	体育	物理	化学
刘备	82	99	99	良	49	85
关羽	81	93	98	中	63	86
张飞	76	99	98	差	82	93
马超	69	99	98	优	40	81
黄忠	50	74	90	优	64	75
魏延	46	55	52	良	90	76
甘宁	44	92	67	优	35	70
张辽	18	93	99	中	58	77
吕布	52	63	64	优	55	53

对 DF_score，做如下筛选操作

5）筛选出所有数学分数在 90 以上且体育成绩不是差的学生数据到名为 DFnew 的新 DataFrame 中

显示 DFnew，如下所示

姓名	语文	数学	英语	体育	物理	化学
刘备	82	99	99	良	49	85
关羽	81	93	98	中	63	86
马超	69	99	98	优	40	81
甘宁	44	92	67	优	35	70
张辽	18	93	99	中	58	77

代码文件 Ex7-2B.py 已给出，内有部分未完成代码，用 pycharm 编辑该文件，参考注释提示完成。

本题注意，由于数据文件中有中文，打开 score.csv 查看数据后，关闭时如果提示是否需要保存，一定要选否！

● 练习 7-3 对 excel 和 csv 文件的读写

Ex7-3A、操作引导

课堂上我们讲授了使用 pandas 读写 excel 的案例。回忆课堂上讲授的内容，如果不熟悉的同学，最好将讲授过的案例自己写一遍。

Ex7-3B、操作实践

读取文件“checkup.csv”和“guangdong.xlsx”并输出为其他文件

使用 pandas 完成下列操作

1) 导入 pandas

读取

2) 读取 CSV 文件“checkup.csv”到 DataFrame 数据框 DF31，将第 2 行作为列标签 columns
3) 读取 Excel 文件“guangdong.xlsx”中的“population”工作表到 DataFrame 数据框 DF32，只读取“年份”、“城镇人口”、“乡村人口”这 3 列

写入

4) 将 DF31 输出到名为“check.xlsx”的 excel 文件中，工作表名为“answer”，从 C 列开始写入，不输出行标签 index 结果如下图所示

	A	B	C	D	E	F	G
1			Patient	Syst.	MAP	Diast.	HR
2			Adam	147	127	110	84
3			Bob	149	128	110	95
4			Clarke	150	128	110	85
5			David	140	126	106	108

answer +

5) 将 DF32 输出到名为“gd.csv”的 csv 文件中,结果如下图所示

*gd.csv - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
,年份,城镇人口,乡村人口
0,2011,6986,3519
1,2012,7140,3454
2,2013,7212,3432
3,2014,7292,3432
4,2015,7454,3395
5,2016,7611,3388
6,2017,7802,3367
7,2018,8022,3324
8,2019,8226,3295
```

py 脚本文件已提供，里面有代码部分内容及提示，请根据提示完成，注意不能更改已有的代码

● 选做

本题为 pandas 综合处理，前面的题目完成的同学可尝试完成本题。

7-4-1 数据综合处理

数据文件说明

数据文件“body_datas.csv”保存着一批人体测量数据，包括身高、体重、颈围、胸围等。如下图所示（部分）

body_datas.csv - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
id,age,weight,height,neck,chest,Abdomen,hip,Thigh,Knee,Ankle
1,23,70,172.1,36.2,93.1,85.2,94.5,59,37.3,21.9
2,22,78.6,183.5,38.5,93.6,83,98.7,58.7,37.3,23.4
3,22,69.8,168.3,34,95.8,87.9,99.2,59.6,38.9,24
4,26,83.8,183.5,37.4,101.8,86.4,101.2,60.1,37.3,22.8
```

数据列说明：

age：年龄

weight：体重，单位为 kg

height：身高，单位为厘米

neck 到 Ankle：身体各部位尺寸，单位为厘米

使用 pandas，完成以下要求

1）读取数据文件到 DF_body，以 id 作为行标签 index

2）从 DF_body 中筛选出年龄高于 45，体重大于 70kg 的数据到名为 DFQ 的新 DataFrame 数据库

3）在 DFQ 中增加一列 BMI，通过 BMI 公式计算出 BMI 值。(计算还未讲，同学根据课件自己尝试)

4）将 DFQ 中的年龄、体重、BMI、胸围数据保存为 Excel 文件 result.XLSX，工作表名 body

本题不提供代码文件，请根据题目要求自行编程

result.XLSX 文件如下图所示

	A	B	C	D	E	F
1	id	age	weight	BMI	chest	
2	36	49	87	31.91722	118.5	
3	38	50	89.2	29.66652	105.6	
4	40	50	92.1	31.79366	114.8	
5	43	48	98.4	31.12659	113.3	
6	51	47	71.8	21.3232	90.2	

body +