实验 08

实验目的

对于 pandas 库：掌握 DataFrame 的计算，掌握 pandas 综合操作，掌握简单统计指标的计算，理解 pyplot 绘图的基本步骤，理解线图绘制

实验内容

本次实验主要有 6 个练习。B 小题已提供 py 脚本程序文件，不需要再新建文件。文件内已有的代码不能修改删除；不能建立新行（题目特别提示除外）
8-5 为课堂选做，请同学自行思考。课堂上无法完成的请在课后完成。
8-6 为课后练习
注意：不要在 pycharm 中打开 csv 文件！！！

作业提交

将上周实验 7 的 7-2B 和本周实验的 8-2B 的代码截图上传到超星学习通的“实验作业 03”中。

使用说明

将“实验 08 学生文件”**整个文件夹**复制到个人文件夹中使用。

练习 8-1 DataFrame 的计算

Ex8-1A、操作引导

课堂上我们讲授了对 Dataframe 的简单运算和 eval 函数的使用。案例代码如下。

```
import pandas as pd
DF1 = pd.read_csv("Diabetes.csv",index_col=0)
DF2 = DF1.iloc[:6, :5]
# 使用索引进行简单计算
DF2["Glucose"] = (DF2["Glucose"] / 18).round(1)
# 使用 eval 函数进行计算
DF2.eval("BMI=Weight/(Height/100)**2", inplace=True)
print(DF2)
```

在 pycharm 中新建 py 文件，将方框内代码复制到代码窗口中，检查无误后运行。
观察运行结果，理解两种运算表达方式的区别

Ex8-1B、操作实践

仿照 8-1A 完成下面的操作。

读取“Diabetes.csv”文件到 DF1，对于 DF1

1.使用 eval 函数将血糖值数据单位转换为 mmlo/L

2.临床上常使用 Mosteller 公式用于估算患者的体表面积 BSA，该公式如下

$$\sqrt{\frac{身高*体重}{3600}}$$ 身高单位为厘米，体重单位为公斤

不使用 eval 函数，仅使用列索引简单计算方式，添加 BSA 列并算出患者对应体表面积，结果保留 2 位小数
结果如下所示(部分)

	Age	Gender	Height	Weight	Glucose	HTN	Smoking	Type	BSA
PatientID									
A01	60	Male	162.5	43.3	16.038889	1	0	1	1.40
A02	63	Male	183.9	73.1	11.538889	0	0	1	1.93
A03	52	Male	149.4	51.5	5.883333	1	0	1	1.46
A04	64	Female	143.5	41.3	14.955556	0	0	1	1.28
A05	44	Male	176.1	61.4	12.938889	1	1	2	1.73
A06	55	Female	141.2	54.6	16.283333	1	0	1	1.46
A07	69	Female	189.9	88.5	6.600000	0	0	2	2.16

py 脚本文件已提供，里面有代码部分内容及注释提示，请根据提示完成，注意不能更改已有的代码，不能增加或删除代码行。

练习 8-2 pandas 综合

Ex8-2A、操作实践

复习课件中关于 pandas 中的排序函数 sort_values 和替换函数 replace 的内容，理解这两个函数的用法

Ex8-2B、操作实践

文件 info.xlsx 为一个包括不同数据信息的 excel 文件。

info.xlsx 中的 checkup 工作表，为患者的信息表，包括姓名、国籍体温等信息

1) 读取 info.xlsx 中的 checkup 工作表，不读取 gender、HR 和 disease 三列，以 name 列为行标签 index，以第 2 行为列标签 columns，数据保存为 DataFrame 数据框并命名为 DF_check

2) DF_check 的”weight”列中，数据的单位为磅，按照 1 公斤= 2.204 磅的换算公式，将”weight”列的数据换算为公斤值，存放在新的一列”weight_kg”中，本题必须使用 eval 函数

3) DF_check 的”temp”列为患者的体温，数据单位为华氏温度值，按照华氏=摄氏*1.8+32 的换算公式，将”temp”列的数据全部替换为摄氏温度值，保留小数点后 1 位，本题不能使用 eval 函数

4) 对 DF_check 数据框，将"country"中所有的国家缩写 EN 替换为 UK

5) 对 DF_check 数据框，将体温 temp 按升序排序，体重 weight 按降序排序

6) 筛选出国籍为美国(US)或者体温大于 37.3 摄氏度的所有患者到新的 DataFrame，命名为 DFout

7) 将 DFout 输出到 excel 文件”result.xlsx”，工作表名为 test，从工作表的 C 列开始放置

结果 result.xlsx 文件如下所示

	A	B	C	D	E	F	G	H
1			name	country	temp	weight	weight_kg	
2			Alejandro W	US	36.3	156.7	71.098	
3			Amelia Vazq	US	36.4	152.3	69.10163	
4			Oliver Geo	US	36.4	134.6	61.07078	
5			Colton Kha	US	36.4	125.8	57.07804	
6			Natalie Kau	US	36.6	154.5	70.09982	
7			Lucy Jone	US	36.6	119.2	54.08348	
8			Savannah Ste	US	36.7	207.4	94.10163	

test +

py 脚本文件已提供，里面有代码部分内容及注释提示，请根据提示完成，注意不能更改已有的代码，不能增加或删除代码行。

● 练习 8-3 数据可视化入门（折线图）

Ex8-3A、操作引导

课堂上我们讲授了使用 matplotlib 绘图需要 7 个步骤。使用了如下的案例：

对某患者，从 0 时开始每隔 15 分钟测量一次血糖，持续 24 小时，共测得血糖 96 次。测量结果保存在 glu.csv 文件中，数据如图所示（部分）。order 列表示测量次数，blood_glucose 列表示测得的血糖值。根据文件中的数据制作统计图。结果示意图

order	blood_glucose
1	9.8
2	9.3
3	9.5
4	9
5	8.8

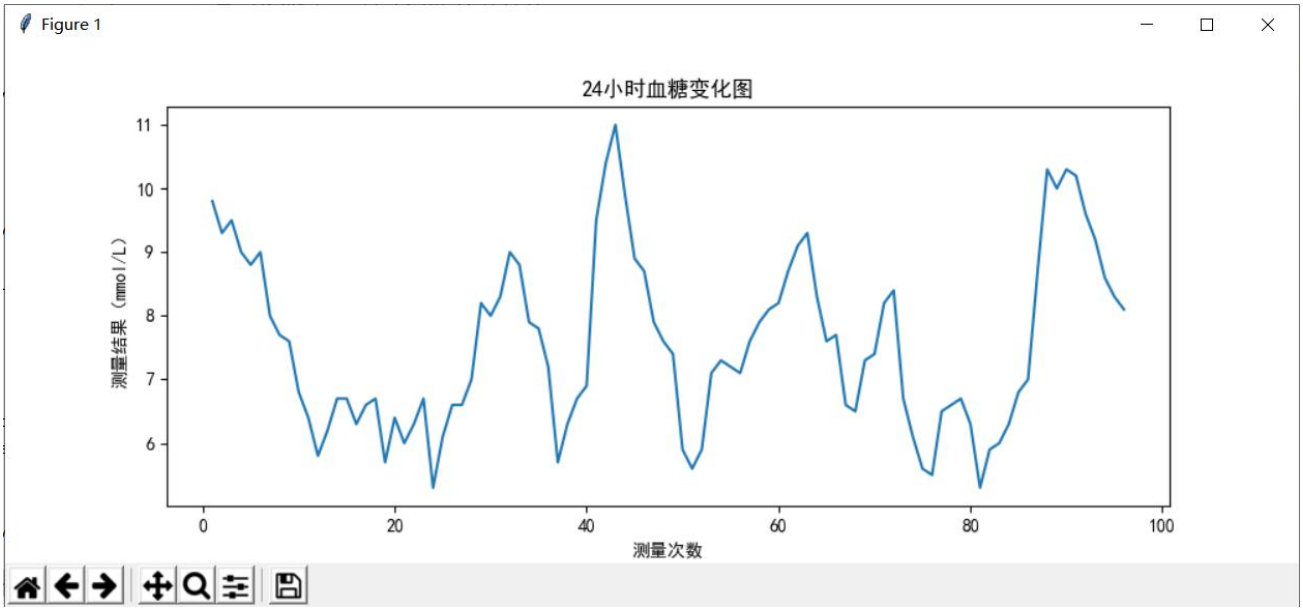

案例代码如下

```
# 步骤 1：导入需要的库
import pandas as pd
import matplotlib.pyplot as plt
# 步骤 2：数据准备
datas = pd.read_csv("GLU.csv")
x = datas["order"].values
y = datas["blood_glucose"].values
# 步骤 3：中文显示修正
plt.rcParams["font.family"] = ["SimHei"]
# 步骤 4：创建绘图对象
plt.figure(figsize=(10, 4))
# 步骤 5：调用相关绘图函数
plt.plot(x, y)
# 步骤 6：外观设置
plt.title('24 小时血糖变化图')
plt.xlabel('测量次数')
plt.ylabel('测量结果（mmol/L）')
# 步骤 7：结果输出
plt.show()
```

pycharm 中新建 py 文件，将代码输入到 pycharm 中检查无误后运行。
观察运行结果，理解数据可视化的步骤，理解折线图函数的使用

练习 8-4 pyplot 绘制线图

Ex8-4A、操作引导

我们在课堂上讲解了使用 pyplot 子库中使用 plot 函数制作线图的代码，案例为制作血压变化折线图，代码如下

```
import matplotlib.pyplot as plt
systolic = [159, 153, 147, 150, 151, 149, 155]
diastolic = [107, 115, 87, 86, 110, 90, 112]
plt.plot(systolic, color="b",linestyle="-", marker="o")
#plt.plot(systolic, "b-o")
plt.plot(diastolic, "r:p")
plt.show()
```

在 pycharm 中新建 py 文件，将方框内代码复制到代码窗口中，检查无误后运行。理解 plot 函数的应用

Ex8-4B、操作实践

参考实验教材 48 页实验八的实验 8-1 的数据完成下面的题目。提示：

1、实验教材 8-1 和 8-2 实际要解决的是一个问题，8-2 在 8-1 的基础上添加了外观属性设置的相关内容。

2、**数据准备部分（读取数据文件并获取列），实践教材上参考答案使用的是 numpy，课堂要求使用 pandas 完成。**

1.实验:中国 AIDS 患者统计图

数据文件 AIDSDATA.CSV 存储的是 2012-2017 年,中国 AIDS 相关的部分统计数据。文件部分内容如下图所示。

发病数	既往感染者转为病人	死亡数
41929	17894	11575
42286	15665	11437
45145	15692	12030
50330	16561	12755
54360	17569	14091

图 8-1 AIDS_DATA.csv 文件示意（部分）

数据文件说明:

“发病数”列:指当年新增加的 AIDS 患者。

“既往感染者转为病人”列:指以前是 HIV 病毒携带者但未发病,于当年发病的患者。

“死亡数”列:指当年死亡的 AIDS 患者。

每列数据共 6 行(不包括标题行),从上到下分别表示 2012 年、2013 年直到 2017 年各年的数据。

程序运行后根据该数据制作表示发病数、感染者转为病人数、死亡数的折线图,三条折线绘制在同一个图形中。将图形保存为 aids.png 文件并显示。三条线的颜色、线形、点型分别为：红色，实线，实心方形标记数据点；蓝色，破折线，星形标记数据点；洋红，虚线，菱形标记。结果如图所示

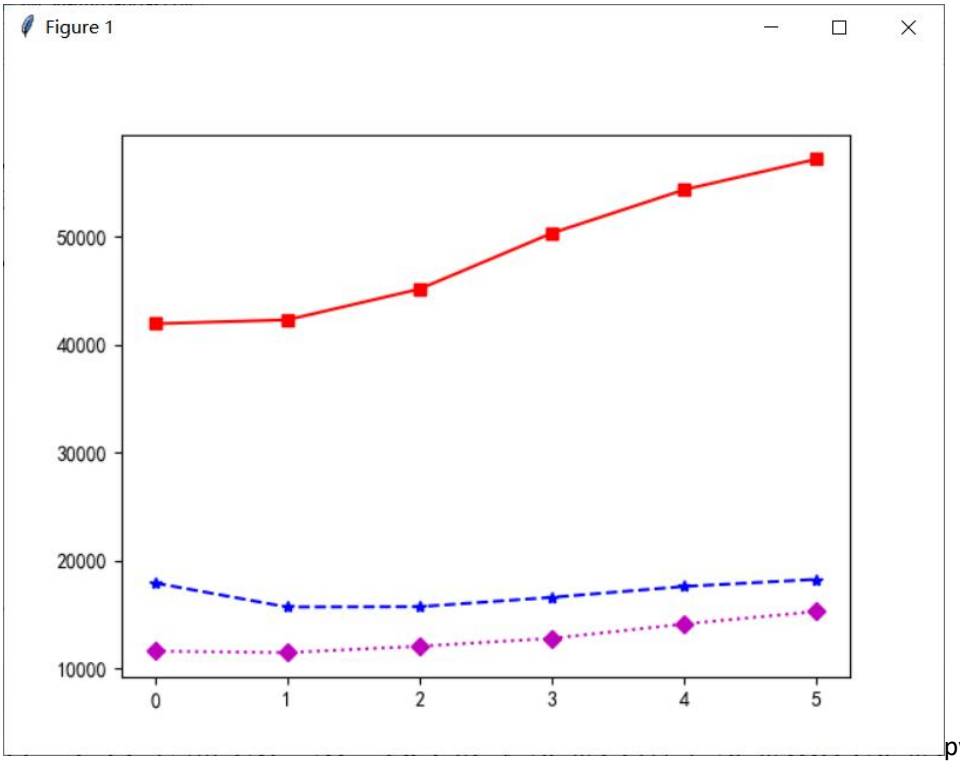

py 脚本文件已提供，里面有代码部分内容及注释提示，请根据提示完成，注意不能更改已有的代码，不能增加或删除代码行。

● 练习 8-5 选做

完成前面实验中未完成的练习

Ex8-5-1

数据文件说明

数据文件“body_datas.csv”保存着一批人体测量数据，包括身高、体重、颈围、胸围等。如下图所示（部分）

body_datas.csv - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
id,age,weight,height,neck,chest,Abdomen,hip,Thigh,Knee,Ankle
1,23,70,172.1,36.2,93.1,85.2,94.5,59,37.3,21.9
2,22,78.6,183.5,38.5,93.6,83,98.7,58.7,37.3,23.4
3,22,69.8,168.3,34,95.8,87.9,99.2,59.6,38.9,24
4,26,83.8,183.5,37.4,101.8,86.4,101.2,60.1,37.3,22.8
```

数据列说明：

age：年龄

weight：体重，单位为 kg

height：身高，单位为厘米

neck 到 Ankle：身体各部位尺寸，单位为厘米

使用 pandas，完成以下要求

1）读取数据文件到 DF3，以 id 作为行标签 index

2）统计并显示年龄的平均值和臀围的标准差，均保留小数点后 2 位

3）从 DF3 中筛选出年龄高于 45，体重大于 70kg 的数据到名为 DF3Q 的新 DataFrame

4）在 DF3Q 中增加一列 BMI，通过 BMI 公式计算出 BMI 值

5）计算统计颈围和 BMI 的相关系数

6）将 DF3Q 中的年龄、体重、BMI、胸围数据保存为 Excel 文件 DF3.XLSX，工作表名 body

本题不提供代码文件，请根据题目要求自行编程

结果如图所示

```
年龄的均值是 44.88
臀围的标准差是 6.51
颈围和BMI的相关系数为 0.6153234223587876
```

● 课后练习

● 练习 8-6 pandas 的数据统计

Ex8-6A、操作引导

课堂上我们讲授了 pandas 的统计操作。回顾课堂讲授内容，案例代码如下。

```
import pandas as pd
DF1 = pd.read_csv("Diabetes.csv",index_col=0)
DF2 = DF1.iloc[:6, :5]
print(DF2["Age"].mean())  # 年龄的均值
print(DF2["Height"].median())  # 身高的中位数
print(DF2["Weight"].max())  # 体重最大值
print(DF2["Glucose"].std().round(3))  # 血糖值的标准差（保留 3 位小数）
print(DF2[["Height","Weight"]].corr())  # 身高体重的相关系数
print(DF2.describe())  # 基本统计指标
```

在 pycharm 中新建 py 文件，将方框内代码复制到代码窗口中，检查无误后运行。
观察运行结果，熟悉在 pandas 中进行统计的方式

Ex8-6B、操作实践

redcell.csv 文件中保存着某次大规模体检中，所有男性受检人员的红细胞计数，共 32116 条数据。
数据文件左图所示。各列数据说明如下

SID　受检者编号

redcell　受检者红细胞计数

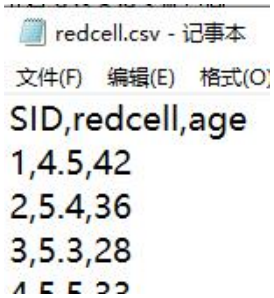

age　受检者年龄

观察文件内容并完成下面的要求：

读取该文件，参考答案图片，完成需要的数据统计。

年龄的均值：33.51205006850168
年龄的中位数：33.0
红细胞方差：0.15
红细胞标准差：0.38
基本统计指标：

	redcell	age
count	32116.0	32116.0
mean	5.2	33.5
std	0.4	9.3
min	3.6	18.0
25%	4.9	25.0
50%	5.2	33.0
75%	5.5	42.0
max	6.8	49.0

py 脚本文件已提供，里面有代码部分内容及提示，请根据提示完成，注意不能更改已有的代码，不能增加代码行。
提示：

1.读取时以数据文件的第 1 列作为 index 行标签

2.方差、标准差保留 2 位小数、基本统计指标保留 1 位小数

3.思考：如果求年龄均值改为，求前一万条年龄数据的均值，代码该如何修改？